Домашнее задание 1

Выберите датасет рекомендательных систем, реализуйте пять моделей с нуля и проведите воспроизводимое сравнение персональных top-10 рекомендаций. Работу оформите в открытом репозитории GitHub.

Датасет

Используемая выборка после очистки должна содержать от 100 000 до 2 000 000 взаимодействий, не менее 1 000 пользователей и 1 000 объектов. Из более крупных данных можно сформировать воспроизводимую подвыборку; опишите способ отбора.

Нужны идентификаторы пользователей и объектов, наблюдаемые взаимодействия и метаданные: timestamp, названия, категории, описания или другие признаки. Данные должны подходить для FM с метапризнаками и выбранной пятой модели. Для timeSVD++ необходимы временные метки и подходящий сигнал оценок.

Запрещены MovieLens, Netflix Prize, Last.fm, их подвыборки, переработанные версии и копии, а также датасеты из семинаров курса. Приведите ссылку на первоисточник и способ получения данных.

Модели

1. Коллаборативная фильтрация на основе соседей: user-based или item-based. Меру сходства и способ формирования рекомендаций выберите самостоятельно.
2. Один из вариантов ALS: для явной или неявной обратной связи, в зависимости от данных и постановки задачи.
3. SLIM или EASE — на выбор.
4. Факторизационная машина (FM) с метапризнаками пользователей, объектов или взаимодействий. Только user/item ID недостаточно. Обоснуйте выбор признаков; используйте лишь информацию, доступную в момент рекомендации.
5. timeSVD++ с временными компонентами либо ALS/iALS с самостоятельно разработанным целевым сигналом. Для кастомного таргета приведите формулу, обоснование и сравнение с базовым ALS/iALS из пункта 2 по единому протоколу.

В пятой модели изменение гиперпараметров или только весов confidence не заменяет разработку целевого сигнала. Для каждого метода кратко опишите постановку и основные формулы.

Самостоятельно реализуйте обучение, вычисление предсказаний и формирование рекомендаций. Разрешены NumPy, SciPy, pandas/Polars, PyTorch (включая autograd), визуализация и инструменты подбора гиперпараметров. Готовые реализации рекомендательных моделей и готовые обучаемые алгоритмы вместо реализации метода, например ElasticNet для SLIM, запрещены.

Эксперименты и ноутбук

Основной ноутбук — experiments.ipynb. Он должен последовательно содержать:

1. Загрузку и описание данных: название, ссылку на источник, смысл полей и взаимодействий, исходный и итоговый объём. Объясните, что рекомендуете и что считаете релевантным объектом.
2. EDA и подготовку: пропуски, дубликаты, активность пользователей, популярность объектов, разреженность и анализ метаданных. Обоснуйте очистку, фильтрацию и формирование подвыборки.
3. Протокол оценки: train/validation/test, набор кандидатов, обработку новых пользователей и объектов, правила исключения уже известных объектов. При наличии timestamp используйте временное разбиение; иначе обоснуйте выбранный способ.
4. Использование всех пяти моделей из models/, подбор гиперпараметров на validation и описание пространства поиска. До подбора выберите основную метрику. Test используйте для финального сравнения после выбора настроек.
5. Сравнение на минимум двух самостоятельно выбранных метриках при K = 10. Обоснуйте их связь с задачей. Приведите общую таблицу результатов и выбранных гиперпараметров.
6. Выводы: какие методы и настройки оказались лучше, как повлияли метаданные или кастомный сигнал, какие ограничения есть у эксперимента. Подкрепляйте выводы полученными результатами.

Для всех моделей используйте одинаковые разбиения, пользователей, кандидатов и правила оценки. Разные обучающие таргеты моделей не должны менять общий критерий релевантности на test.

Репозиторий

Создайте открытый репозиторий GitHub со следующей структурой:

README.md — ФИО студента, название датасета и ссылка на него.

experiments.ipynb — основной ноутбук с выполненными ячейками, графиками и таблицами результатов.

models/ — отдельный .py-файл для каждой модели. Общие вспомогательные функции можно вынести отдельно.

requirements.txt — зависимости для запуска работы.

.gitignore — исключения для данных, окружения, кешей и тяжёлых файлов. Директория data/ в структуре репозитория не требуется; сами данные в GitHub не загружайте.

Добавьте в ноутбук инструкции загрузки данных и запуска. Зафиксируйте случайные зерна и параметры экспериментов, чтобы работу можно было повторить. Результат сдачи — ссылка на открытый репозиторий.